



جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat



Centre Régional Africain des Sciences et Technologies de l'Espace en Langue Française (CRASTE-LF), Affilié à l'ONU

MASTER EN SCIENCE ET TECHNOLOGIE DE L'ESPACE

**Option: Télédétection et Systèmes d'Information Géographique
Promotion: 2023-2025**

Module: Rapport de Traitement D'Image Avancée

Rapport de Traitement D'Image Avancée

Présenté par:
SEYDI Lamine

Encadré par:
**M. Mouad Alami-Machichi et
Mme. Soumia El. A Ismaili**

Résumé :

Durant ce projet, nous avons mis en œuvre une approche en deux étapes pour la classification supervisée d'une image satellite en utilisant l'algorithme de machine learning RandomForest intégré dans QGIS via l'OTB. Dans un premier temps, une classification non supervisée a été réalisée pour identifier les différentes classes présentes dans l'image. Ensuite, une classification supervisée a été effectuée pour affiner ces classes. Les résultats obtenus ont montré des performances satisfaisantes dans la prédiction des classes de l'image. Cependant, la résolution de l'image a constitué une limitation notable, notamment pour l'identification des objets de petite taille tels que les véhicules. À travers ce travail, nous avons renforcé notre compréhension des concepts clés du machine learning et du traitement avancé des images, tout en prenant conscience des défis posés par la résolution des images satellites.

Table des matières

Introduction -----	5
I. Description de la donnée-----	6
I.1. Description de la zone d'étude -----	7
I.2. Description de la méthode de collecte de la donnée -----	7
II. Classification non supervisée de la zone -----	8
III. Prétraitement de la donnée -----	9
1. Les Classes -----	9
2. L'Echantionnage-----	9
3. La Segmentation -----	10
4. Séparation des données d'entrainement et test-----	13
VI. Création d'un modèle -----	16
1. Entrainement du modèle -----	16
2. Evaluation du modèle -----	17
VIII. Résultat de la classification avec le modèle -----	18
1. Cartographie de la prédiction du modèle-----	18
IX. Utilisation du modele de machine learning random forest -----	19
1. Entrainement du modèle Random Forest -----	19
2. Evaluation du modèle obtenue avec Random Forest -----	20
X. Comparaison entre réalité et prédiction du modèle -----	22

Liste des figures

Figure 1: Carte de description de la donnée-----	4
Figure 2 : Carte image NAIP de la zone d'étude -----	7
Figure 3 : Carte de la Classification non supervisée de la zone -----	8
Figure 4 : Carte de repartition de l'ensemble des Échantillons dans la zone d'étude-----	9
Figure 5 : Carte de la Segmentation-----	10
Figure 6 : Table attributaire du fichier de sortie de la segmentation-----	11
Figure 7 : Table attributaire du fichier de sortie de la jointure -----	12
Figure 8 : Carte de représentation de la jointure -----	12
Figure 9 : Table attributaire du fichier de sortie de la zonal statistics -----	13
Figure 10 : Représentation des étapes de la separation des données-----	14
Figure 11 : Table representative des données test-----	14
Figure 12 : Table representative des données d'entraînement-----	14
Figure 13 : Carte de separabilité des données d'entraînement et des données tests-----	15
Figure 14 : Cartographie de la prédiction du modèle -----	18
Figure 15 : Carte de Comparaison entre réalité et prédiction du modèle-----	22

Liste des tableaux

Tableau 1 : Représentation de la matrice de confusion	16
Tableau 2 : Tableau des métriques d'évaluation du modèle	17
Tableau 3 : : Représentation de la matrice de confusion issue du model de machine learning Random Forest	19
Tableau 4 : Tableau des métriques d'évaluation du modèle machine learning Random Forest	20

Introduction

La classification des images satellites est une technique cruciale dans le domaine de la télédétection, permettant de transformer des données brutes en informations géospatiales utiles. Dans ce projet intitulé "Classification Supervisée d'une Image Satellite avec Algorithme de Machine Learning de OTB", nous avons exploré l'utilisation de l'algorithme RandomForest intégré dans QGIS via l'Orfeo ToolBox (OTB) pour réaliser une classification supervisée d'une image satellite.

L'approche adoptée s'articule en deux étapes distinctes : une classification non supervisée initiale pour identifier les grandes classes de l'image et une classification supervisée pour affiner ces classes et améliorer la précision. Cette méthodologie permet de combiner les forces des deux types de classification pour obtenir des résultats plus robustes.

Les résultats de notre étude ont démontré des performances satisfaisantes dans la prédiction des classes, malgré certaines limitations liées à la résolution de l'image, notamment pour l'identification des objets de petite taille. Ce projet a non seulement permis de renforcer notre compréhension des techniques avancées de machine learning appliquées à la télédétection, mais a également mis en lumière les défis inhérents à l'analyse des images satellites.

I. Description de la donnée

L'image utilisée tout au long de ce projet est une image satellite au format JP2 (JPEG 2000), connue pour sa capacité de compression sans perte, ce qui permet de conserver une haute qualité d'image tout en réduisant la taille des fichiers. L'image couvre une zone située aux États-Unis, plus précisément dans l'État de Californie. Elle est téléchargeable depuis Google Explorer et est accessible via le dictionnaire de données du Programme National d'Imagerie Agricole (PNIA). Le Système géodésique est basé sur le NAD83 (Système géodésique nord-américain 1983). La projection cartographique utilisée est : UTM WGS 1984 Sphère Auxiliaire Web Mercator, l'image contient 4 bandes spectrales, ce qui permet une analyse multispectrale détaillée des différentes classes présentes dans l'image.




Figure 1: Carte de description de la donnée

I.1. Description de la zone d'étude

Pour optimiser le traitement avancé de l'image dans notre projet, nous avons initialement travaillé sur une image de grande taille. Afin de rendre le processus plus efficace et fluide, nous avons extrait une zone d'intérêt (ROI) spécifique de cette image. Cette approche ciblée nous a permis de concentrer nos efforts sur une portion représentative de la zone d'étude, facilitant ainsi l'analyse et réduisant le temps de traitement. Après avoir défini cette zone d'intérêt, nous avons appliqué un filtrage rigoureux pour améliorer la détection des éléments constitutifs de la région analysée. Ce processus de segmentation et de filtrage a été crucial pour affiner les détails et maximiser la précision des résultats obtenus. À la suite de cette explication, les deux cartes ci-après illustrent respectivement la zone d'étude extraite et la zone d'étude filtrée.




Figure 2 : Carte image NAIP de la zone d'étude




Figure 3 : Carte image NAIP de la zone d'étude filtrée

I.2. Description de la méthode de collecte de la donnée

Dans le cadre de ce projet, nous avons utilisé une image issue du Programme National d'Imagerie Agricole (PNIA), téléchargeable depuis Google Explorer et accessible via le dictionnaire de données du programme. Bien que cette donnée soit généralement collectée de manière autonome par les chercheurs, nous avons eu l'avantage de recevoir directement l'image de notre professeur du module de traitement avancé d'image. Cette source fiable et précise nous a permis de nous concentrer pleinement sur les aspects analytiques et méthodologiques du projet, garantissant ainsi une qualité optimale des résultats obtenus.

II. Classification non supervisée de la zone

Afin d'avoir une vue d'ensemble des classes potentielles présentes dans notre zone d'étude, nous avons réalisé une classification non supervisée en utilisant l'outil K-means classification d'OTB dans QGIS. Cette approche exploratoire nous a permis d'identifier cinq catégories principales d'objets les plus apparents sur l'image: la végétation, les bâtiments, la pelouse, l'eau et le sol nu. Cette classification initiale a fourni une base solide pour notre analyse ultérieure, en nous permettant de cibler les caractéristiques distinctes et de mieux comprendre la répartition des différentes classes dans la zone d'intérêt. Ci-dessous, nous présentons la carte résultant de cette classification non supervisée, illustrant les différentes catégories identifiées.




Figure 3 : Carte de la Classification non supervisée de la zone

III. Prétraitement de la donnée

1. Les Classes

La classification non supervisée précédemment réalisée avait pour objectif principal de faciliter le choix des classes pour la classification supervisée ultérieure. À partir de cette analyse préliminaire, nous avons identifié cinq classes distinctes dans notre image : la végétation, les bâtiments, la pelouse, l'eau et le sol nu. Afin de maintenir la cohérence et de tirer parti des informations obtenues, nous avons décidé de conserver ces mêmes cinq classes pour la classification supervisée. Cette continuité dans le choix des classes nous a permis de réaliser un échantillonnage ciblé et efficace, garantissant une meilleure précision et pertinence des résultats finaux.

2. L'Echantionnage

Nous avons entamé l'échantillonnage en créant un nouveau shapefile de type point pour collecter des échantillons représentatifs de chaque classe. À l'issue de cette opération, nous avons rassemblé un nombre significatif d'échantillons pour chaque classe, en tenant compte de la densité respective des objets dans l'image. Ci-dessous, nous présentons la carte des échantillons collectés, illustrant la répartition des points de collecte dans notre zone d'étude.





Figure 4 : Carte de répartition de l'ensemble des Échantillons dans la zone d'étude

3. La Segmentation

La segmentation permet de découper l'image en objets représentant différentes caractéristiques terrestres. Pour réaliser cette opération dans QGIS avec l'extension OTB, nous avons sélectionné l'algorithme de segmentation "MeanShift" et opté pour le mode de traitement de type "vecteur". Le schéma ci-après en ai une parfaite illustration.



Les étape de la segmentation

Le fichier de sortie de la segmentation est un fichier vectoriel au format .shp, représentant la segmentation de tous les éléments présents dans l'image de notre zone d'étude.





Figure 5 : Carte de la Segmentation

La table attributaire résultante de cette segmentation contient un champ nommé par défaut "DN", comprenant un total de 28,851 valeurs distinctes. Ci-dessous, nous présentons l'illustration de la table attributaire issue de cette segmentation.



	DN
1	1
2	2
3	3
4	4
5	5
6	6
7	7
8	8

Montrer toutes les entités

Figure 6 : Table attributaire du fichier de sortie de la segmentation

Après la segmentation, nous avons procédé à une jointure basée sur la localisation des objets. À cette fin, nous avons utilisé l'outil "Joindre les attributs par localisation" dans QGIS, où nous avons fusionné les données issues de la segmentation avec la couche des points d'échantillonnage pour comparaison. Nous avons sélectionné la méthode "intersect" pour identifier les intersections entre les entités, en choisissant le type de jointure "première entité correspondante" pour garantir que seul le premier segment intersecté soit retenu en cas de chevauchement. Cette approche nous a permis d'enrichir les segments segmentés avec les informations des points d'échantillonnage. Ci-dessous, nous présentons la carte résultante de cette jointure ainsi que sa table attributaire illustrant les résultats obtenus avec les valeurs des means, standard deviation (stdev), min et max.

Jointure — Total des entités: 1311, Filtrées: 1311, Sélectionnées: 0

	DN	count	mean_0	stdev_0	min_0	max_0
1	33	208,000000000...	101,276051961...	9,84910812869...	73,0000000000...	120,000000...
2	48	154,000000000...	51,5746158005...	7,50519074143...	40,8181800842...	75,2500000...
3	64	1358,00000000...	189,105720924...	5,88916841742...	117,500000000...	219,000000...
4	65	251,000000000...	50,3588020659...	9,33467384628...	35,4000015258...	83,0000000...
5	66	213,000000000...	59,8863156636...	8,54375285670...	39,6250000000...	74,6153869...
6	70	112,000000000...	173,109839984...	7,95870921242...	147,699996948...	186,781250...
7	90	462,000000000...	60,8879247805...	11,0845655869...	41,5000000000...	89,3333358...
8	91	310,000000000...	78,0678311624...	7,10626214462...	45,0000000000...	95,0000000...

Montrer toutes les entités

Figure 8 : Table attributaire du fichier de sortie de la jointure





Figure 7 : Carte de représentation de la jointure

4. Séparation des données d'entraînement et test

Avant de procéder à la séparation des données d'entraînement et de validation par classe, nous avons d'abord calculé les statistiques des données. Pour ce faire, nous avons utilisé l'outil "ZonalStatistics" de l'extension OTB dans QGIS. Ce calcul statistique nous a fourni plusieurs mesures essentielles pour évaluer la répartition et les caractéristiques des classes. Grâce à ces statistiques, nous avons pu optimiser la séparation des données, garantissant ainsi une représentativité adéquate des classes pour l'entraînement et la validation du modèle. Ci-dessous, nous présentons une illustration du résultat de ZonalStatistics, illustrant les résultats obtenus.



	DN	count	mean_0	stdev_0	min_0	max_0
1	1	303,000000000...	87,6469232414...	12,1682293201...	53,0000000000...	115,73332
2	2	143,000000000...	95,7854775382...	9,83426702101...	66,0000000000...	120,00000
3	3	128,000000000...	72,2192010581...	9,85516014722...	48,0000000000...	95,000000
4	4	289,000000000...	105,712634525...	24,5849477929...	65,0000000000...	180,00000
5	5	388,000000000...	92,2686259672...	16,4863680822...	50,0000000000...	130,85714
6	6	114,000000000...	75,8349336322...	7,35039237612...	62,3750000000...	102,00000
7	7	213,000000000...	84,7946353249...	22,1431906498...	26,0000000000...	128,00000
8	8	173,000000000...	49,5393691972...	7,97770397999...	36,1666679382...	66,545455

Figure 9 : Table attributaire du fichier de sortie de la zonal statistics

Les étapes de la séparation des données

Pour effectuer cette opération, nous avons accédé à l'interface « vecteur », puis « outil de recherche » et enfin "sélection aléatoire". Grâce à cette interface, nous avons pu tout d'abord sélectionner les données d'entraînement à 75% puis on inverse la sélection pour les données de test, assurant ainsi une répartition optimale des données.




Figure 10 : Représentation des étapes de la separation des données

Jointure — Total des entités: 1311, Filtrées: 1311, Sélectionnées: 328

	DN	count	mean_0	stdev_0	min_0	max_0
107	974	291,000000000...	66,7198472301...	9,39146344952...	40,0000000000...	87,00000000...
108	986	101,000000000...	83,8939204452...	4,84158438506...	72,0000000000...	101,857139...
109	1043	164,000000000...	70,9872002950...	8,58899150167...	51,0000000000...	86,00000000...
110	1044	338,000000000...	78,7906264920...	19,6045108822...	37,0000000000...	157,000000...
111	1072	545,000000000...	68,4647620384...	10,9986026534...	37,0000000000...	105,750000...
112	1080	422,000000000...	63,3041166423...	10,2737898488...	38,0000000000...	90,3333358...
113	1084	188,000000000...	71,6264279142...	8,39816668461...	46,5000000000...	90,00000000...
114	1118	266,000000000...	63,9204865219...	6,41508754075...	46,5555572509...	78,00000000...

Montrer toutes les entités

Données Test: 328/1311

Figure 11 : Table representative des données test

Jointure — Total des entités: 1311, Filtrées: 1311, Sélectionnées: 983

	DN	count	mean_0	stdev_0	min_0	max_0
107	974	291,000000000...	66,7198472301...	9,39146344952...	40,0000000000...	87,00000000...
108	986	101,000000000...	83,8939204452...	4,84158438506...	72,0000000000...	101,857139...
109	1043	164,000000000...	70,9872002950...	8,58899150167...	51,0000000000...	86,00000000...
110	1044	338,000000000...	78,7906264920...	19,6045108822...	37,0000000000...	157,000000...
111	1072	545,000000000...	68,4647620384...	10,9986026534...	37,0000000000...	105,750000...
112	1080	422,000000000...	63,3041166423...	10,2737898488...	38,0000000000...	90,3333358...
113	1084	188,000000000...	71,6264279142...	8,39816668461...	46,5000000000...	90,00000000...
114	1118	266,000000000...	63,9204865219...	6,41508754075...	46,5555572509...	78,00000000...

Montrer toutes les entités

Données d'entraînement: 983/1311

Figure 12 : Table representative des données d'entraînement

Ci-dessous, nous présentons la carte de séparabilité des données d'entraînement et de test, illustrant les résultats obtenus. Les données d'entraînement représentant 75% des données permettant d'entraîner le modèle et les données de test qui représentent 25% des données permettant la validation du modèle.




Figure 13 : Carte de séparabilité des données d'entraînement et des données tests

En résumé, les étapes de prétraitement des données ont été essentielles pour garantir la précision et l'efficacité de notre analyse. Nous avons commencé par extraire une zone d'intérêt de l'image initiale, puis appliqué des techniques de filtrage et de segmentation pour identifier les différents éléments terrestres. Ensuite, une jointure des données a permis de fusionner les segments avec les points d'échantillonnage, suivie d'une analyse statistique pour optimiser la séparation des données d'entraînement et de validation. Ces étapes ont posé des bases solides pour la création de notre modèle de classification basé sur les objets.

VI. Création d'un modèle

1. Entrainement du modèle

L'outil "TrainVectorClassifier" de l'extension OTB sur QGIS nous a permis de créer le modèle de classification. Dans la fenêtre ouverte, nous avons introduit les données d'entraînement comme entrée et les données de test dans la partie "validation vector data". Par défaut, nous avons laissé l'algorithme libsvm sous l'option "classifier to use for the training". Enfin, nous avons spécifié les fichiers de sortie pour le modèle et la matrice de Confusion. Ci-dessous, nous présentons l'illustration de cette procédure, accompagnée de la matrice de confusion résultante.

	[1]	[2]	[3]	[4]	[5]
[1]	156	0	0	0	0
[2]	1	129	0	0	4
[3]	0	0	4	0	0
[4]	3	0	0	16	0
[5]	0	2	0	0	13

Tableau 1 : Représentation de la matrice de confusion

La matrice de confusion obtenue montre des performances variées pour chaque classe. La classe 1 (arbres) présente une très haute précision de 0.975 avec 156 instances correctement classées et aucune instance mal classée, indiquant une excellente sensibilité. La classe 2 (bâtiments) a une précision de 0.984733 avec 129 instances correctement classées, mais montre une légère confusion avec 1 arbre et 4 sols nus. La classe 3 (eau) est parfaitement classée avec une précision de 1.0, bien que l'échantillon soit petit avec seulement 4 instances. La classe 4 (pelouse) a une bonne précision de 1.0 mais une sensibilité légèrement inférieure (0.842105) avec 16 instances correctement classées et une confusion avec 3 arbres. Enfin, la classe 5 (sol nu) présente la plus grande confusion avec une précision de 0.764706, indiquant des difficultés à distinguer cette classe des bâtiments. Globalement, l'indice de Kappa de 0.949143 montre une très bonne concordance entre les prédictions du modèle et les classes réelles. Voici l'illustration de la matrice de confusion résultante

2. Evaluation du modèle

Tableau 2 : Tableau des métriques d'évaluation du modèle

Classe	Précision	Rappel	F-score	Performance Globale
Arbres [1]	0.975	1.0	0.987342	0.949143
Bâtiments [2]	0.984733	0.962687	0.973585	
Eau [3]	1.0	1.0	1.0	
Pelouse [4]	1.0	0.842105	0.914286	
Sol nu [5]	0.764706	0.866667	0.8125	

Le modèle de classification basé sur les objets a démontré une performance globale remarquable avec un indice Kappa de 0.949143, indiquant une très haute concordance entre les classes prédites et les classes réelles. Ces résultats soulignent l'efficacité du modèle à discriminer les différentes classes présentes dans notre zone d'étude.

VIII. Résultat de la classification avec le modèle

1. Cartographie de la prédiction du modèle

Pour visualiser les résultats obtenus, voici la cartographie de la prédiction du modèle, illustrant la répartition des différentes classes dans notre zone d'étude.

La carte ci-dessous représente la cartographie de la prédiction du modèle, montrant la classification des différentes classes de notre zone d'étude : arbres, bâtiments et routes, eaux, pelouse, et sol nu. La matrice de confusion en haut à gauche de la carte montre les résultats de la classification.




Figure 14 : Cartographie de la prédiction du modèle

En analysant cette carte, on constate que les zones prédominantes d'arbres et de pelouses ont été bien identifiées, ainsi que les zones bâties et les surfaces d'eau. La précision globale et l'indice de Kappa élevés attestent de la fiabilité du modèle. La plupart des erreurs de classification se situent principalement entre les classes de bâtiments et de sols nus, ce qui peut être attribué à des similarités spectrales entre ces deux classes dans les données d'entrée.

IX. Utilisation du modele de machine learning random forest

Le même procédé a été utilisé pour l'entraînement du modèle cette fois avec une particularité qui est l'intégration du modèle de machine learning random forest dans les parametre de l'outil "TrainVectorClassifier" de l'extension OTB sur QGIS. Nous avons introduit les données d'entraînement comme entrée et les données de test dans la partie "validation vector data" et avons changé l'algorithme « libsvm » par « rf » qui est le random forest sous l'option "classifier to use for the training". Ci-dessous, nous présentons l'illustration de cette procédure, accompagnée de la matrice de confusion résultante légèrement differente de la précédente.

1. Entrainement du modèle Random Forest

Tableau 3 : : Représentation de la matrice de confusion issue du model de machine learning Random Forest

	[1]	[2]	[3]	[4]	[5]
[1]	155	0	1	0	0
[2]	1	133	0	0	0
[3]	0	0	4	0	0
[4]	7	1	0	11	0
[5]	0	6	0	0	9

Cette matrice de confusion présente les résultats de la classification pour cinq classes: arbres (classe 1), bâtiments (classe 2), eau (classe 3), pelouse (classe 4), et sol nu (classe 5). La classe des arbres montre une excellente précision avec 155 instances correctement classées sur 156. Les bâtiments sont également bien classifiés avec 133 instances correctes. L'eau a une classification parfaite avec 4 instances correctes. La pelouse montre une certaine confusion avec les arbres et un total de 11 instances correctes sur 19. Enfin, la classe du sol nu montre une confusion notable avec les bâtiments, avec seulement 9 instances correctement classées sur 15. Globalement, la classification est satisfaisante pour les classes majoritaires, mais pourrait être améliorée pour les classes pelouse et sol nu.

2. Evaluation du modèle obtenue avec Random Forest

Tableau 4 : Tableau des métriques d'évaluation du modèle machine learning Random Forest

Classe	Précision	Rappel	F-score	Performance Globale
Arbres [1]	0.95092	0.99359	0.971787	0.916741
Bâtiments [2]	0.95	0.992537	0.970803	
Eau [3]	0.8	1	0.888889	
Pelouse [4]	1	0.578947	0.733333	
Sol nu [5]	1	0.6	0.75	

Le modèle de classification Random Forest montre une performance globale solide avec des précisions et des rappels élevés pour la plupart des classes, bien que le rappel soit plus faible pour les classes "Pelouse" et "Sol nu". Globalement, les F-scores indiquent une bonne adéquation du modèle aux données.

3. Cartographie de la prédiction du modèle obtenue avec random forest

La carte ci-dessous représente la cartographie de la prédiction du modèle de classification Random Forest, montrant la classification des différentes classes de notre zone d'étude : arbres, bâtiments et routes, eaux, pelouse, sol nu,




Figure 15 : Cartographie de la prédiction du modèle avec Random Forest

X. Comparaison entre réalité et prédiction du modèle

L'image ci-dessous illustre la comparaison entre la réalité et la prédiction du modèle. À gauche, nous avons la cartographie de la prédiction du modèle, représentant la répartition des différentes classes dans notre zone d'étude: arbres, bâtiments et routes, eaux, pelouse, et sol nu. À droite, une image satellite de la même zone permet de visualiser la correspondance entre la classification supervisée et la réalité terrain.




Figure 16 : Carte de Comparaison entre réalité et prédiction du modèle

Cette comparaison visuelle confirme la précision et la fiabilité de notre modèle de classification basé sur les objets, validée par la matrice de confusion et les métriques d'évaluation élevées.

Conclusion

Le projet de traitement d'image avancée a permis de démontrer l'efficacité des techniques de télédétection et d'apprentissage automatique dans la classification des différentes classes d'occupation du sol dans la région de Draa Tafilalet. En intégrant des outils tels que QGIS et l'extension OTB, nous avons pu effectuer un prétraitement minutieux des données, suivi par la création d'un modèle de classification basé sur les objets. L'utilisation de l'algorithme Random Forest a généré des résultats prometteurs, validés par une matrice de confusion et des métriques d'évaluation de haute précision, recall et F-score pour chaque classe. La cartographie des prédictions et l'analyse de la confiance du modèle ont renforcé la robustesse et la fiabilité de notre approche. Ce projet met en lumière l'importance des méthodes de traitement d'image avancée dans la gestion et l'analyse des ressources géospatiales.

Nous tenons à exprimer notre gratitude à M. Mouad Alami-Machichi et Mme. Soumia El A. Ismaili pour leur enseignement précieux et leur soutien dans le cadre du module de traitement d'image avancée. Leur expertise et leur dévouement ont été essentiels à la réussite de ce projet.